

Reporte de Prueba de Usabilidad

LIMA v0.1 — Linux Intelligent Middleware Assistant

Prueba comparativa intra-sujeto: entorno gráfico vs. asistente de voz

Segunda tanda de sesiones

Universidad Tecnológica de la Mixteca

Instituto de Computación — Ingeniería en Computación

Tesis de Licenciatura, 2026

Elaboró: José Ramón Aragón Toledo

Director de tesis: M.C. Ricardo Ruiz Rodríguez

Contacto: `aatr010423@gs.utm.mx`

Dirigido a: Laboratorio de Usabilidad (USALAB)

Fecha de las sesiones: Junio de 2026

Fecha del reporte: 24 de junio de 2026

Sesión piloto (excluida del análisis): U1 — condición A (DeepSeek)

Participantes analizados: 14 (U2–U15)

Condición A (DeepSeek): U3, U5, U7, U9, U10, U12, U14

Condición B (OpenAI GPT-4o): U2, U4, U6, U8, U11, U13, U15

Documento de uso interno elaborado para su depósito en el Laboratorio de Usabilidad (USALAB). Contiene datos de participantes recabados bajo consentimiento informado.

Resumen Ejecutivo

Producto evaluado: LIMA v0.1 (*Linux Intelligent Middleware Assistant*) es un asistente de voz para el sistema operativo GNU/Linux que traduce instrucciones en lenguaje natural a comandos del sistema, con el objetivo de reducir la barrera de entrada para usuarios novatos.

Metodología: Se realizó una prueba de usabilidad comparativa intra-sujeto: cada participante ejecutó las mismas tres tareas primero con el **entorno gráfico** (ratón y teclado) y después **por voz** con LIMA. Se evaluaron 14 participantes (excluida la sesión piloto U1), divididos en dos condiciones de modelo de lenguaje: condición A con DeepSeek ($n = 7$) y condición B con OpenAI GPT-4o ($n = 7$). Los indicadores se alinean con la norma ISO 9241-11: *eficacia*, *eficiencia* y *satisfacción*.

Resultados principales		
Indicador	Entorno gráfico	Voz (LIMA)
Eficacia global (3 tareas)	100 %	83,9 % promedio
– Tarea 1 (carpetas)	100 %	80,8 %
– Tarea 2 (mover PDF)	100 %	78,6 %
– Tarea 3 (búsqueda web)	100 %	92,3 %
Tiempo medio T1	119,4 s	248,1 s (×2,1)
Tiempo medio T2	55,2 s	136,9 s (×2,5)
Tiempo medio T3	30,3 s	69,0 s (×2,3)
Calificación general (1–10)	8,21 ± 0,97 (cuestionario final)	
Facilidad de aprendizaje (1–5)	4,54 ± 0,66	
Satisfacción (1–5)	3,62 ± 0,77	

Recomendación general: LIMA recibe una valoración positiva de parte de los usuarios novatos en GNU/Linux, especialmente en facilidad de aprendizaje. Sin embargo, la eficacia por voz (83,9 %) y la naturalidad percibida (3,46/5) indican que el manejo de comandos de voz requiere mejoras en robustez y en la gestión de errores. Se recomienda priorizar la retroalimentación al usuario cuando LIMA no comprende la instrucción.

Agradecimientos

Este reporte fue elaborado por **José Ramón Aragón Toledo**, autor de la tesis de la que forma parte la evaluación aquí descrita. El autor agradece al equipo que hizo posible la segunda tanda de pruebas de usabilidad:

- Al **Ing. David del Castillo**, técnico del Laboratorio de Usabilidad (USALAB), quien fungió como técnico durante las sesiones de prueba y preparó el entorno y el registro de cada sesión.
- Al compañero **Fray Fabián Ortiz Ortiz**, estudiante de Ingeniería en Computación, por su colaboración como parte del equipo de evaluación durante las sesiones.
- Al **M.T.I. Mario Alberto Moreno** (Maestría en Tecnología de Información), por su orientación en materia de Interacción Humano-Computadora y evaluación de usabilidad, ámbito en el que cuenta con una sólida trayectoria de investigación [2].

Índice

Resumen Ejecutivo	2
Agradecimientos	3
1. Introducción	5
1.1. Justificación de la evaluación	5
1.2. Descripción del producto evaluado	5
1.3. Contexto de uso definido	5
1.4. Objetivos de la prueba	5
2. Metodología	7
2.1. Participantes	7
2.2. Tareas evaluadas	8
2.3. Escenario de prueba	8
2.4. Instrumentación	9
2.5. Procedimiento	9
2.6. Diseño experimental	9
2.7. Métricas de usabilidad (ISO 9241-11)	10
3. Resultados	11
3.1. Eficacia	11
3.2. Eficiencia	11
3.2.1. Eficiencia por condición de modelo	12
3.3. Satisfacción	12
3.3.1. Facilidad de uso post-tarea	12
3.3.2. Cuestionario final de satisfacción	12
3.3.3. Disposición a volver a usar y a recomendar	13
3.3.4. Preferencia de modalidad por tarea	13
4. Análisis y Discusión	14
4.1. Interpretación de la eficacia	14
4.2. Interpretación de la eficiencia	15
4.2.1. Comparación por condición de modelo	15
4.3. Interpretación de la satisfacción	16
4.4. Observaciones cualitativas relevantes (casos particulares)	17
4.5. Limitaciones del estudio	18
5. Conclusiones y Recomendaciones	19
5.1. Hallazgos principales	19
5.2. Recomendaciones priorizadas	19
5.3. Trabajo futuro	20
Referencias	21
Anexos	22

1. Introducción

1.1. Justificación de la evaluación

GNU/Linux es un sistema operativo ampliamente utilizado en entornos académicos y de desarrollo de software; sin embargo, su curva de aprendizaje representa una barrera significativa para usuarios que provienen de sistemas operativos comerciales con interfaz gráfica (Windows o macOS). La línea de comandos, en particular, exige un vocabulario técnico y una sintaxis precisos que resultan poco intuitivos para usuarios novatos.

LIMA (*Linux Intelligent Middleware Assistant*) surge como respuesta a esta barrera: permite al usuario interactuar con el sistema operativo mediante instrucciones en lenguaje natural hablado, sin necesidad de memorizar comandos. La prueba de usabilidad descrita en este reporte tiene como propósito medir, de forma controlada, si LIMA realmente facilita la realización de tareas cotidianas en GNU/Linux para este perfil de usuario.

1.2. Descripción del producto evaluado

LIMA v0.1 es un asistente de voz que corre en segundo plano sobre GNU/Linux. El usuario activa LIMA mediante una palabra de activación (*wake word*), dicta una instrucción en español y el asistente la interpreta, genera el comando correspondiente y lo ejecuta en el sistema. Internamente, LIMA emplea un modelo de lenguaje grande (*LLM*) para la comprensión de la instrucción y la generación del comando.

En esta evaluación se probaron dos configuraciones de modelo (*condiciones*):

- **Condición A:** modelo DeepSeek.
- **Condición B:** modelo OpenAI GPT-4o.

Las funcionalidades directamente evaluadas fueron:

- Creación de directorios (carpetas y subcarpetas).
- Movimiento de archivos entre directorios.
- Apertura del navegador web con una búsqueda específica.

1.3. Contexto de uso definido

El contexto de uso en que se diseñó la evaluación es el de un **estudiante universitario (18–33 años) sin experiencia previa en GNU/Linux** que necesita realizar tareas básicas de organización de archivos en el sistema operativo para una asignatura. Se asumió que el participante maneja con fluidez Windows o macOS a nivel usuario (crear carpetas, abrir archivos, navegar en internet) pero desconoce la interfaz de GNU/Linux.

1.4. Objetivos de la prueba

1. Medir la **eficacia** (tasa de éxito) con la que usuarios novatos completan tres tareas representativas usando, por un lado, el entorno gráfico y, por el otro, el asistente de voz LIMA.
2. Medir la **eficiencia** (tiempo de tarea) de ambas modalidades de interacción.

3. Evaluar la **satisfacción** subjetiva de los usuarios hacia LIMA mediante escalas Likert y preguntas abiertas post-tarea.
4. Comparar los resultados entre la condición A (DeepSeek) y la condición B (OpenAI GPT-4o) para detectar diferencias atribuibles al modelo de lenguaje.

2. Metodología

2.1. Participantes

Se realizaron 15 sesiones en total. La primera sesión (U1, condición A, DeepSeek) funcionó como **sesión piloto** para verificar el protocolo; sus datos *no se incluyen* en el análisis. Las 14 sesiones restantes (U2–U15) constituyen la muestra analizada.

Criterios de reclutamiento:

- Edad entre 18 y 25 años (criterio orientativo).
- Poca o nula experiencia con GNU/Linux.
- Manejo de Windows o macOS a nivel usuario (crear carpetas, mover archivos, navegar en internet).
- Sin formación avanzada en administración de sistemas ni uso habitual de la línea de comandos.
- Motivación real o potencial para aprender Linux.
- Cuota mínima de género: al menos la mitad mujeres.

Nota sobre el perfil: Una persona completó el formulario de pre-registro pero se retiró antes de iniciar la sesión; sus datos se excluyen del análisis. Todos los participantes analizados se ubicaron dentro del rango de edad de inclusión (18–33 años). Algunos participantes reportaron experiencia frecuente con la terminal, lo que puede haber influido en los tiempos de tarea con entorno gráfico.

La Tabla 1 resume las características de los 14 participantes analizados.

Cuadro 1: Características de los participantes (U2–U15, $n = 14$).

ID	Sx.	Edad	Carrera	Exp. Linux	SO habitual	Cond.
U2	M	31	Tecnológica	Nunca	macOS	B (GPT-4o)
U3	H	22	Ing. Computación	Nunca	Windows	A (DeepSeek)
U4	H	23	Ing. Computación	Frecuente	Linux	B (GPT-4o)
U5	H	27	Ing. Computación	Frecuente	Windows	A (DeepSeek)
U6	M	28	Ing. Diseño	Casi nunca	Windows	B (GPT-4o)
U7	M	25	Ing. Electrónica	Ocasional	Windows	A (DeepSeek)
U8	M	23	Ing. Diseño	Casi nunca	Windows	B (GPT-4o)
U9	H	32	M.C.M	Nunca	macOS	A (DeepSeek)
U10	M	26	Mtría. Medios Interactivos	Frecuente	Windows	A (DeepSeek)
U11	M	25	Ing. Alimentos	Nunca	Windows	B (GPT-4o)
U12	H	28	Mtría. en IA	Frecuente	Windows	A (DeepSeek)
U13	H	23	Ing. Computación	Frecuente	Windows	B (GPT-4o)
U14	H	25	Ing. Computación	Ocasional	Windows	A (DeepSeek)
U15	H	23	Ing. Computación	Frecuente	Windows	B (GPT-4o)

Sx.: Sexo. H = Hombre, M = Mujer.

Los 14 participantes tienen datos de pre-registro completos. La distribución de género es 8 hombres y 6 mujeres. Las condiciones están equilibradas: 7 participantes en condición A (DeepSeek) y 7 en condición B (GPT-4o).

2.2. Tareas evaluadas

Se definieron tres tareas representativas del contexto de uso descrito. El orden de las tareas fue fijo para todos los participantes ($T1 \rightarrow T2 \rightarrow T3$).

Cuadro 2: Descripción de las tareas evaluadas.

Tarea	Descripción	Criterio de éxito
T1	Crear en el Escritorio la carpeta 302-A con 6 subcarpetas (una por materia: Matemáticas discretas, Cálculo, Cultura y sociedad, Teoría de la computación, Bases de datos, Programación orientada a objetos).	Existe la carpeta 302-A en el Escritorio y contiene las 6 subcarpetas con nombres reconocibles.
T2	Localizar el PDF <code>Temario_Programacion.pdf</code> en la carpeta de Descargas y moverlo a la subcarpeta de <i>Programación orientada a objetos</i> dentro de 302-A.	El PDF no está en Descargas y se encuentra en la subcarpeta de POO dentro de 302-A.
T3	Realizar una búsqueda en internet sobre la definición o ejemplos de la Programación Orientada a Objetos y abrir los resultados en el navegador.	Se muestra en el navegador una búsqueda relevante sobre POO.

Cada tarea se ejecutó en dos versiones (en este orden):

- A. Con **entorno gráfico**: el participante usa ratón y teclado, sin asistencia de voz.
- B. Con **voz** (LIMA): el participante dicta la instrucción a LIMA.

Tiempo límite por tarea: 12 minutos. Si se supera, se registra *no éxito* y se pasa a la siguiente tarea.

Escala de éxito:

- **Sí** (100 %): tarea completada correctamente, con o sin ruta alternativa.
- **Parcial** (50 %): tarea incompleta pero con avance significativo.
- **No** (0 %): tarea no completada o superado el tiempo límite.

2.3. Escenario de prueba

Las sesiones se realizaron en instalaciones de la Universidad Tecnológica de la Mixteca. El equipo configurado para cada sesión incluía:

- Computadora de escritorio o portátil con GNU/Linux instalado y entorno de escritorio gráfico.
- Conexión a internet activa.
- Micrófono para la captura de voz del participante.

- LIMA v0.1 en ejecución con la condición de modelo asignada (DeepSeek o GPT-4o).
- Estado inicial del sistema: escritorio limpio (sin carpeta 302-A previa) y al menos 3 archivos PDF en ~/Descargas, uno de ellos nombrado `Temario_Programacion.pdf`.
- Notificaciones del sistema silenciadas durante la sesión.

2.4. Instrumentación

- **Formulario de pre-registro** (en línea): datos demográficos, experiencia previa con Linux y motivación.
- **Hoja de Observador** (formulario en línea de 127 campos): registraba tiempos de inicio y fin de cada tarea (con o sin voz), criterios de éxito, niveles de frustración observados, calificaciones post-tarea y cuestionario final de satisfacción.
- **Cronómetro integrado** en el formulario (marcas de tiempo automáticas).
- **Observador** presente durante toda la sesión para registrar datos y cumplir el protocolo sin intervenir en la ejecución de las tareas.

2.5. Procedimiento

La estructura de cada sesión fue la siguiente:

1. **Bienvenida y consentimiento** (≈ 3 min): el facilitador explicaba el propósito de la evaluación, aclaraba que se evaluaba el sistema y no al participante, y solicitaba el pensamiento en voz alta.
2. **Escenario general** (≈ 2 min): se presentaba el contexto (estudiante del grupo 302-A al inicio del semestre).
3. **Ejecución de tareas** (≈ 35 min): para cada tarea (T1, T2, T3) el participante la completaba primero con entorno gráfico y luego con voz (LIMA).
4. **Preguntas post-tarea** (tras cada tarea): facilidad percibida (escala 1–5) para entorno gráfico y para voz; preferencia y motivos.
5. **Cuestionario final** (≈ 5 min): calificación global, satisfacción, facilidad de aprendizaje, naturalidad, accesibilidad, velocidad percibida y disposición a recomendar.
6. **Cierre y reseteo del entorno**: el facilitador agradecía al participante y restauraba el estado inicial del sistema.

Regla de oro del facilitador: nunca se indicaba *cómo* realizar una tarea; solo se describía el resultado esperado (*qué* lograr). Si el participante solicitaba ayuda directa para completar la tarea, se registraba como *no éxito*.

2.6. Diseño experimental

- **Diseño intra-sujeto** para la variable *modalidad de interacción*: cada participante realizó las mismas tres tareas primero con entorno gráfico y después con voz. El orden modalidad gráfica $\rightarrow$ modalidad de voz fue fijo para todos.

- **Diseño entre-sujetos** para la variable *condición de modelo de lenguaje*: a cada participante se le asignó una sola condición (A: DeepSeek o B: GPT-4o), alternando por sesión.
- Las variables controladas incluyeron: el escenario (mismo contexto narrativo), las tareas, el estado inicial del sistema, el guión del facilitador y la presencia del observador.

2.7. Métricas de usabilidad (ISO 9241-11)

Los indicadores de esta evaluación se estructuran según las tres dimensiones de usabilidad de la norma ISO 9241-11 [1]: eficacia, eficiencia y satisfacción. Este marco es el mismo que la revisión sistemática de Pal et al. [6] consolida como referencia para evaluar asistentes de voz, lo que facilita el contraste de estos resultados con el estado del arte.

Eficacia Tasa de éxito por tarea y modalidad:

$$\text{Eficacia} = \frac{\sum w_i}{n} \times 100 \% \quad \text{donde } w_i \in \{1,0; 0,5; 0,0\}$$

Se reportan conteos de Sí / Parcial / No y la tasa resultante.

Eficiencia

Tiempo empleado en cada tarea, tanto en la versión con entorno gráfico como en la versión por voz. Se reportan media, desviación estándar, mínimo y máximo. Para comparar ambas modalidades se calcula:

$$\Delta T = \frac{t_{\text{gráf}} - t_{\text{voz}}}{t_{\text{gráf}}} \times 100$$

Un valor positivo indica que LIMA fue más rápido; negativo, más lento.

Satisfacción

Se midió con:

- Escala de facilidad post-tarea (1–5): aplicada por separado para entorno gráfico (P1) y para voz (P2).
- Cuestionario final: calificación global (1–10), satisfacción, facilidad de aprendizaje, naturalidad, accesibilidad y velocidad percibida (todos 1–5 salvo la calificación).

3. Resultados

3.1. Eficacia

La Tabla 3 presenta los resultados de eficacia por tarea y modalidad. En la modalidad gráfica, todos los participantes completaron las tres tareas de forma exitosa (100 %). En la modalidad de voz, la eficacia fue inferior en las tres tareas, con mejora progresiva de T1 a T3 conforme los participantes ganaban familiaridad con el asistente.

Cuadro 3: Eficacia por tarea y modalidad ($n = 14$, salvo donde se indica). Sí = éxito completo (100 %), Parcial = éxito parcial (50 %), No = sin éxito (0 %). La tasa de éxito ponderada usa $w \in \{1,0; 0,5; 0\}$.

Tarea	Entorno gráfico				Voz (LIMA)			
	Sí	Parc.	No	Tasa	Sí	Parc.	No	Tasa
T1 – Organizar carpetas	14	0	0	100,0 %	9	3	1	80,8 %^a
T2 – Mover temario PDF	14	0	0	100,0 %	10	2	2	78,6 %
T3 – Búsqueda web	14	0	0	100,0 %	12	0	1	92,3 %^a
Promedio				100,0 %				83,9 %

^aUn participante no registró resultado en esta celda de voz ($n = 13$).




Figura 1: Tasa de completitud (eficacia) por tarea y modalidad.

La tarea con mayor dificultad en voz fue **T1** (crear la estructura de carpetas), que requería dictar una lista de seis nombres de materias. La tarea de menor dificultad en voz fue **T3** (búsqueda web), donde la instrucción es más concisa y directa.

3.2. Eficiencia

La Tabla 4 presenta los tiempos de ejecución por tarea y modalidad. En todas las tareas, la modalidad de voz requirió entre 2,1 y 2,5 veces más tiempo que el entorno gráfico.

La alta desviación estándar en los tiempos de voz (especialmente en T1: $DE = 202,4s$ y T2: $DE = 130,6s$) refleja una gran variabilidad entre participantes: algunos completaron la tarea rápidamente con una sola instrucción mientras otros necesitaron varias reformulaciones o tuvieron que esperar a que LIMA procesara la petición.

Cuadro 4: Tiempos de ejecución en segundos por tarea y modalidad ($n = 14$). Se reportan media ($\bar{x}$), desviación estándar (DE), mínimo y máximo.

Tarea	Entorno gráfico (s)				Voz — LIMA (s)			
	$\bar{x}$	DE	Mín	Máx	$\bar{x}$	DE	Mín	Máx
T1 – Carpetas	119,4	39,5	51	181	248,1	202,4	61	773
T2 – Mover PDF	55,2	32,2	24	124	136,9	130,6	50	507
T3 – Búsqueda	30,3	15,9	9	65	69,0	44,0	26	187

Cuadro 5: Índice de eficiencia relativa ΔT y ratio de tiempo entre modalidades.

Tarea	$\bar{x}$ gráfico	$\bar{x}$ voz	Ratio
T1 – Carpetas	119,4 s	248,1 s	Voz $\times$ 2,1 más lento
T2 – Mover PDF	55,2 s	136,9 s	Voz $\times$ 2,5 más lento
T3 – Búsqueda	30,3 s	69,0 s	Voz $\times$ 2,3 más lento

3.2.1. Eficiencia por condición de modelo

Cuadro 6: Comparación de tiempos medios (en segundos) de la modalidad de voz según condición de modelo ($n_A = 7$, $n_B = 7$).

Tarea	Voz A (DeepSeek)	Voz B (GPT-4o)	GUI A	GUI B
T1	273,9 s	222,3 s	134,4 s	104,4 s
T2	121,6 s	152,3 s	41,6 s	68,9 s
T3	81,7 s	54,2 s	32,9 s	27,7 s

3.3. Satisfacción

3.3.1. Facilidad de uso post-tarea

Tras cada tarea, se preguntó a los participantes qué tan fácil les pareció realizarla con el entorno gráfico (P1) y con la voz (P2), en una escala del 1 (muy difícil) al 5 (muy fácil).

Los valores de facilidad percibida son altos en ambas modalidades (por encima de 3,5/5 en todos los casos). La voz fue calificada de forma similar o ligeramente superior al entorno gráfico en T2 y T3, a pesar de los tiempos mayores.

3.3.2. Cuestionario final de satisfacción

Al concluir las tres tareas, se aplicó un cuestionario de satisfacción general. La Tabla 8 muestra los resultados globales y por condición.

La jerarquía de dimensiones —facilidad de aprendizaje como la mejor valorada (4,54/5) y naturalidad como la peor (3,46/5)— reproduce la observada en la literatura de asistentes de voz: la facilidad de aprendizaje es comparable al ~ 90 % de usuarios que la consideran sencilla en estudios longitudinales [7], mientras que la naturalidad es la cualidad más difícil de satisfacer incluso para los asistentes comerciales [3].




Figura 2: Tiempos de ejecución (en segundos) por tarea, modalidad y condición de modelo.

Cuadro 7: Facilidad de uso percibida post-tarea (escala 1–5). Media y DE.

Tarea	Entorno gráfico (P1)		Voz — LIMA (P2)	
	$\bar{x}$	DE	$\bar{x}$	DE
T1 – Carpetas	4,14	0,95	4,23	0,83
T2 – Mover PDF	3,67	1,44	4,38	1,19
T3 – Búsqueda	4,31	0,85	4,31	0,48

3.3.3. Disposición a volver a usar y a recomendar

De los 13 participantes que respondieron:

- **Volvería a usar LIMA:** 6 “Definitivamente sí”, 5 “Probablemente sí”, 1 “Tal vez”, 1 “Probablemente no”. Media: 4,23/5.
- **Recomendaría LIMA** (de 11 que respondieron): 7 “Definitivamente sí”, 3 “Probablemente sí”, 1 “Definitivamente no”. Media: 4,36/5.

3.3.4. Preferencia de modalidad por tarea

En T1 (crear estructura de carpetas), la voz fue la modalidad preferida por la mayoría (8/12), a pesar de haber requerido más tiempo, lo que sugiere que los participantes aprecian el potencial de automatización para tareas repetitivas. En T2 (mover un archivo), la preferencia se dividió por igual entre voz y GUI.

Cuadro 8: Resultados del cuestionario final de satisfacción. Las puntuaciones de satisfacción–accesibilidad son en escala 1–5; la calificación en escala 1–10. Media y DE. ($n = 14$ para calificación; $n = 13$ para el resto por un dato faltante.)

Dimensión	Global	DE	A (DeepSeek)	B (GPT-4o)	n
Calificación (1–10)	8,21	0,97	7,86	8,57	14
Satisfacción (1–5)	3,62	0,77	3,67	3,57	13
Facilidad aprendizaje (1–5)	4,54	0,66	4,33	4,71	13
Naturalidad (1–5)	3,46	1,13	3,50	3,43	13
Accesibilidad (1–5)	4,23	1,01	4,33	4,14	13
Velocidad percibida (1–5)	3,62	1,19	3,50	3,71	13




Figura 3: Calificación general de LIMA por participante (escala 1–10).

4. Análisis y Discusión

4.1. Interpretación de la eficacia

La eficacia del entorno gráfico fue perfecta (100 % en las tres tareas), lo que era esperable dado que todos los participantes tenían experiencia previa con interfaces gráficas de escritorio (Windows o macOS). La eficacia de la modalidad de voz fue inferior (promedio 83,9 %), lo que pone de manifiesto las limitaciones actuales de LIMA ante un primer contacto sin entrenamiento.

Las principales razones de fallo en la modalidad de voz observadas durante las sesiones fueron:

- **T1 (80,8 %):** La instrucción incluía seis nombres de materias que debían dictarse en una sola oración; varios participantes dividieron la petición en múltiples solicitudes o LIMA no creó todas las subcarpetas en un solo paso.
- **T2 (78,6 %):** La tarea requería que LIMA localizara un archivo específico y lo moviera; en algunos casos LIMA movió el archivo a una ruta incorrecta o no encontró el PDF. Fue la tasa más baja de las tres.
- **T3 (92,3 %):** Al ser la instrucción más concisa (“busca en internet...”), la tasa fue la más alta de las tres.

La tarea de búsqueda web (T3) fue la de mayor eficacia, mientras que las que exigían




Figura 4: Comparación de dimensiones del cuestionario final según condición de modelo (A = DeepSeek, B = GPT-4o).

Cuadro 9: Preferencia de modalidad de interacción declarada por los participantes al terminar cada tarea.

Tarea	Voz (LIMA)	Entorno gráfico	Indiferente
T1 – Carpetas	8	1	3
T2 – Mover PDF	5	5	3
T3 – Búsqueda	7	2	4

dictar una lista de elementos (T1) o localizar un archivo concreto (T2) resultaron algo más difíciles para el reconocimiento y la interpretación por voz.

4.2. Interpretación de la eficiencia

La modalidad de voz fue sistemáticamente más lenta que el entorno gráfico en todas las tareas (ratio de $2,1\times$ a $2,5\times$). Este resultado es esperable en un contexto de primera exposición al asistente: la voz introduce latencia de procesamiento y los participantes debían formular verbalmente instrucciones que aún no dominaban. No obstante, la percepción subjetiva de velocidad fue moderada ($3,62/5$), lo que indica que los usuarios no siempre percibieron la diferencia de tiempo como un problema importante.

La alta variabilidad en los tiempos de voz (p.ej., $DE = 202,4s$ en T1) refleja diferencias individuales en la forma de formular las instrucciones: los participantes con más experiencia técnica o con mayor soltura verbal completaron la tarea con una sola instrucción precisa, mientras que otros necesitaron reformular varias veces.

4.2.1. Comparación por condición de modelo

Las diferencias entre condiciones fueron mixtas y de magnitud pequeña, sin un ganador claro. La condición B (GPT-4o) tuvo mayor eficacia de voz y tiempos menores en T1 y T3, mientras que DeepSeek fue más rápido en T2. En el cuestionario final, GPT-




Figura 5: Preferencia de modalidad declarada tras cada tarea.




Figura 6: Nivel de frustración observado por tarea y modalidad.

4o aventajó en calificación global (8,57 frente a 7,86) y facilidad de aprendizaje (4,71 frente a 4,33), en tanto que DeepSeek igualó o superó levemente en naturalidad (3,50 frente a 3,43) y accesibilidad (4,33 frente a 4,14). Dado el tamaño de muestra ($n_A = 7$, $n_B = 7$) y la alta variabilidad interindividual, estas diferencias no son concluyentes. Este resultado mixto es coherente con Brüggemeier et al. [4], quienes, al comparar Alexa, Siri y Google Assistant con cuatro cuestionarios establecidos, observaron que las diferencias entre asistentes dependen del instrumento de medida y rara vez son uniformes; de ahí que esta comparación se presente como exploratoria.

4.3. Interpretación de la satisfacción

La calificación global de 8,21/10 y la disposición mayoritaria a volver a usar LIMA (85 % “probablemente” o “definitivamente” sí) indican una recepción positiva del asistente. La dimensión con valoración más alta fue la **facilidad de aprendizaje** (4,54/5), lo que sugiere que los usuarios percibieron que LIMA es fácil de aprender a usar, aun cuando en términos objetivos la eficacia de voz no fue perfecta.

La dimensión con valoración más baja fue la **naturalidad** (3,46/5), lo que señala que la interacción conversacional de LIMA aún no se percibe tan fluida como una conversación con un asistente humano. Esto puede estar relacionado con los tiempos de procesamiento, con respuestas de LIMA que no siempre correspondían exactamente a lo esperado, o con la curva de aprendizaje del *phrasing* correcto para las instrucciones.

Este patrón es consistente con la literatura sobre asistentes de voz comerciales. Berdasco et al. [3] encontraron que la naturalidad y la corrección de las respuestas




Figura 7: Distribución de la velocidad percibida de LIMA respecto al entorno gráfico (escala 1 = mucho más lento, 5 = mucho más rápido).

son las dimensiones que mejor diferencian a Alexa, Google Assistant, Siri y Cortana, y que ninguno alcanza una naturalidad plena; la naturalidad sigue siendo, por tanto, el reto abierto del dominio y no una carencia exclusiva de LIMA. En contraste, la elevada **facilidad de aprendizaje** de LIMA (4,54/5) es comparable a la observada por Jakob et al. [7], donde cerca del 90 % de los participantes consideraron sencillo aprender a usar el asistente. Finalmente, Zwakman et al. [5] mostraron que una escala genérica como SUS no captura bien la interacción por voz, lo que respalda la decisión de medir la satisfacción de LIMA mediante varias dimensiones específicas (naturalidad, accesibilidad, velocidad percibida) en lugar de una sola puntuación agregada.

4.4. Observaciones cualitativas relevantes (casos particulares)

La gran mayoría de las sesiones transcurrió sin contratiempos. Se documentan, no obstante, los casos particulares que explican los tiempos atípicos y que conviene tener presentes al interpretar los resultados:

- **Sesión piloto (U1) — configuración inicial.** La prueba piloto cumplió su función de validación: durante ella se detectó que el archivo `config.json` no contenía correctamente las credenciales (*API key*) de DeepSeek, por lo que el sistema no generaba respuestas. Se añadieron las credenciales y la sesión continuó con normalidad. El hallazgo confirma el valor del piloto como mecanismo de detección temprana de fallos de configuración. Sus datos se excluyen del análisis.
- **Micrófono inactivo (segundo participante de la condición A, DeepSeek) — sesión de 1:07:00.** El micrófono quedó momentáneamente apagado mientras se daba oportunidad al sistema de cerrar la grabación en el *modo de atención* —que requiere unos segundos de silencio para finalizar la captura de audio—. Con el micrófono inactivo, las tareas siguientes se intentaron sin éxito; al detectar el problema, el facilitador reinició la secuencia, lo que extendió la sesión hasta poco más de una hora. Se trata de una incidencia operativa, no de un fallo del sistema.




Figura 8: Perfil de experiencia de usuario por condición de modelo (radar de las dimensiones del cuestionario final).

- **Sesión más breve (28:00).** En el extremo opuesto, la sesión más corta correspondió a un participante con notable soltura técnica, que formuló sus instrucciones de voz de forma directa y sin reformulaciones. Este caso ilustra la convergencia esperable de los tiempos hacia los valores mínimos a medida que el usuario gana confianza con el asistente.
- **Retiro voluntario.** Una persona completó el formulario de pre-registro pero solicitó retirarse antes de iniciar la sesión; sus datos se descartaron en respeto al derecho de retiro contemplado en el consentimiento informado.

4.5. Limitaciones del estudio

1. **Tamaño de muestra:** con $n = 14$ participantes, los resultados no tienen poder estadístico suficiente para detectar diferencias significativas entre condiciones con pruebas inferenciales; los datos son de naturaleza descriptiva.
2. **Orden fijo de modalidades:** al ejecutar siempre primero el entorno gráfico y luego la voz, existe un posible efecto de *carry-over*: el participante ya conoce la tarea cuando la realiza por voz, lo que puede inflar la tasa de éxito y reducir el tiempo de voz.
3. **Heterogeneidad de la muestra:** algunos participantes tenían experiencia avanzada en Linux (uso frecuente de terminal, Linux como SO principal) mientras que otros nunca lo habían usado, lo que introduce variabilidad no controlada en los tiempos.
4. **Sesión única:** las métricas miden el rendimiento en la primera exposición a LIMA; resultados con usuarios entrenados podrían diferir sustancialmente.

5. Conclusiones y Recomendaciones

5.1. Hallazgos principales

1. **LIMA es usable pero requiere mejoras en robustez.** La eficacia de la modalidad de voz (83,9 % en promedio) está por debajo del 100 % del entorno gráfico; el resto de los intentos resultó en éxito parcial o nulo. Los errores se concentran en instrucciones complejas (crear múltiples carpetas en una sola petición) y en operaciones de localización de archivos.
2. **La voz es significativamente más lenta en primera exposición.** Los usuarios necesitaron entre 2,1 y 2,5 veces más tiempo que con el entorno gráfico. Sin embargo, esta diferencia es esperada en un primer contacto y no parece perjudicar la satisfacción global.
3. **La satisfacción subjetiva es alta.** Calificación media de 8,21/10, con facilidad de aprendizaje como la dimensión mejor valorada (4,54/5). El 85 % de los usuarios volvería a usar LIMA. La naturalidad percibida (3,46/5) es el punto de mejora más señalado. Esta jerarquía es consistente con el estado del arte: la alta facilidad de aprendizaje concuerda con estudios longitudinales de asistentes de voz [7] y la naturalidad rezagada con la dificultad que esta cualidad representa incluso para los asistentes comerciales [3].
4. **La voz fue la modalidad preferida para tareas repetitivas.** En T1 (crear estructura de carpetas) 8 de 12 usuarios prefirieron la voz, lo que sugiere que los usuarios reconocen el valor de la automatización incluso en una primera sesión.
5. **Diferencias mixtas entre modelos.** GPT-4o aventajó en calificación global (8,57 vs. 7,86) y facilidad de aprendizaje (4,71 vs. 4,33), mientras que DeepSeek igualó o superó levemente en naturalidad (3,50 vs. 3,43) y accesibilidad (4,33 vs. 4,14). Con un tamaño de muestra pequeño (7 por grupo), ninguna diferencia es concluyente.

5.2. Recomendaciones priorizadas

- R1. Mejorar el manejo de errores y la retroalimentación al usuario.** Cuando LIMA no puede interpretar o ejecutar una instrucción, debe informar al usuario de forma clara qué salió mal y sugerir cómo reformular la petición. Esto reduciría la frustración y aumentaría la tasa de éxito.
- R2. Optimizar la creación de múltiples directorios en un solo comando.** La tarea T1 (crear seis subcarpetas a la vez) fue la de mayor tasa de fallo. LIMA debería manejar listas de elementos dentro de una misma instrucción, ya sea subdividiéndola internamente o confirmando con el usuario la lista antes de ejecutar.
- R3. Mejorar la naturalidad del diálogo con el usuario.** Las respuestas de LIMA deben ser más concisas y conversacionales. Se recomienda reducir la latencia de respuesta y usar confirmaciones breves (“Hecho. He creado las seis carpetas.”) en lugar de respuestas técnicas.

R4. Ampliar el conjunto de evaluación con una muestra más homogénea. Una segunda ronda de pruebas con participantes estrictamente novatos en Linux (sin experiencia en terminal) y dentro del rango de edad objetivo (18–33 años) permitiría obtener resultados más representativos del usuario meta.

R5. Explorar el diseño contrabalanceado de modalidades. Alternar el orden (voz primero / GUI primero) en futuros estudios eliminaría el efecto de *carry-over* y permitiría medir el rendimiento de voz sin el beneficio previo de haber practicado la tarea.

5.3. Trabajo futuro

- Implementar las correcciones derivadas de R1 y R2, y realizar una tercera tanda de pruebas para medir el impacto de las mejoras.
- Desarrollar un tutorial interactivo de inicio (*onboarding*) que enseñe a los usuarios cómo formular instrucciones efectivas.
- Evaluar LIMA en escenarios más complejos (instalación de paquetes, edición de archivos de configuración) una vez que se consolide la usabilidad en tareas básicas.

Referencias

Referencias

- [1] Organización Internacional de Normalización. (2018). *ISO 9241-11:2018. Ergonomics of human-system interaction — Part 11: Usability: Definitions and concepts*. International Organization for Standardization.
- [2] Kumar, N., Cannanure, V. K., Gamage, D., Prabhakar, A. S., Sturm, C., Loaiza, C. R., Sabie, D., Bhuiyan, M. M. y Moreno Rocha, M. A. (2020, abril). HCI across borders and sustainable development goals. En *Extended Abstracts of the 2020 CHI Conference on Human Factors in Computing Systems* (pp. 1–8). ACM. <https://doi.org/10.1145/3334480.3375067>
- [3] Berdasco, A., López, G., Diaz, I., Quesada, L. y Guerrero, L. A. (2019). User experience comparison of intelligent personal assistants: Alexa, Google Assistant, Siri and Cortana. *Proceedings of UCAmI 2019*, 31(1), 51. <https://doi.org/10.3390/proceedings2019031051>
- [4] Brüggemeier, B., Breiter, M., Kurz, M. y Schiwy, J. (2020). User experience of Alexa, Siri and Google Assistant when controlling music — Comparison of four questionnaires. En *HCI International 2020 — Late Breaking Papers: User Experience Design and Case Studies* (pp. 600–618). Springer. https://doi.org/10.1007/978-3-030-60114-0_40
- [5] Zwakman, D. S., Pal, D. y Arpnikanondt, C. (2021). Usability evaluation of artificial intelligence-based voice assistants: The case of Amazon Alexa. *SN Computer Science*, 2, 28. <https://doi.org/10.1007/s42979-020-00424-4>
- [6] Pal, D., Arpnikanondt, C., Funilkul, S. y Chutimaskul, W. (2022). A systematic review of voice assistant usability: An ISO 9241–11 approach. *SN Computer Science*, 3, 267. <https://doi.org/10.1007/s42979-022-01172-3>
- [7] Jakob, D., Wilhelm, S., Gerl, A., Ahrens, D. y Wahl, F. (2025). Adapting voice assistant technology for older adults. *Digital*, 5(1), 4. <https://doi.org/10.3390/digital5010004>

Anexos

Anexo A: Guión de la sesión de prueba

El guión completo utilizado durante las sesiones (instrucciones para el facilitador, textos leídos al participante, escenarios y procedimientos de transición entre modalidades) se encuentra en el documento `GUION_PRUEBAS.tex` / `GUION_PRUEBAS.pdf` ubicado en el mismo directorio que este reporte.

Anexo B: Estructura de la Hoja de Observador

La Hoja de Observador fue implementada como formulario en línea (127 campos). Registraba los siguientes bloques de información:

- **Metadatos de sesión:** fecha, hora de inicio, ID de usuario, observador, condición asignada.
- **Datos de tarea (T1, T2, T3):** marcas de tiempo de inicio y fin por modalidad (GUI y voz), criterios de éxito individuales, resultado (Sí/Parcial/No), nivel de frustración observado.
- **Preguntas post-tarea:** facilidad percibida (GUI y voz, 1–5), preferencia de modalidad y motivos.
- **Cuestionario final:** calificación global (1–10), satisfacción, facilidad de aprendizaje, naturalidad, accesibilidad, velocidad percibida, disposición a volver a usar y a recomendar, nombre preferido para el asistente y comentarios abiertos.
- **Notas del observador:** observaciones cualitativas durante y al término de la sesión.
- **Checklist de reseteo del entorno.**

Anexo C: Formulario de pre-registro

El formulario de pre-registro capturaba los siguientes datos: género, edad, carrera, experiencia con Linux (frecuencia y tipo de uso), nivel de habilidad en sistemas operativos, SO habitual, uso de la terminal, administración de sistemas y motivación para aprender Linux. Se verificaba el cumplimiento del perfil de usuario objetivo antes de cada sesión.

Anexo D: Tabla completa de participantes (U2–U15)

Fin del reporte de prueba de usabilidad — LIMA v0.1 — Segunda tanda, junio 2026.

Cuadro 10: Datos completos de participantes. n.d. = dato no disponible (no completó el formulario de pre-registro). Las sesiones se realizaron en el orden cronológico indicado.

Orden	ID	Sexo	Edad	Carrera	Exp. Linux	Condición
1	U2	M	31	Tecnológica	Nunca	B (GPT-4o)
2	U3	H	22	Ing. en Computación	Nunca	A (DeepSeek)
3	U4	H	23	Ing. en Computación	Frecuente	B (GPT-4o)
4	U5	H	27	Ing. en Computación	Frecuente	A (DeepSeek)
5	U6	M	28	Ing. en Diseño	Casi nunca	B (GPT-4o)
6	U7	M	25	Ing. en Electrónica	Ocasional	A (DeepSeek)
7	U8	M	23	Ing. en Diseño	Casi nunca	B (GPT-4o)
8	U9	H	32	M.C.M	Nunca	A (DeepSeek)
9	U10	M	26	Mtría. Medios Interactivos	Frecuente	A (DeepSeek)
10	U11	M	25	Ing. en Alimentos	Nunca	B (GPT-4o)
11	U12	H	28	Mtría. en IA	Frecuente	A (DeepSeek)
12	U13	H	23	Ing. en Computación	Frecuente	B (GPT-4o)
13	U14	H	25	Ing. en Computación	Ocasional	A (DeepSeek)
14	U15	H	23	Ing. en Computación	Frecuente	B (GPT-4o)

H = Hombre, M = Mujer.